

# Relatorio

Maxxi Lorenzo Santos Rios, 472722      Alysson da Silva Moura, 400660  
Leonardo Gomes Prado, 472920      Luis Fernando A. Brito, 418824

05/02/2022

## Incluindo os pacotes

Primeiro nós precisamos incluir o pacote `glmnet` que utilizaremos para estimar utilizando os métodos de *shrinkage*

## Questões

Considere os dados sobre automóveis disponíveis no Sigaa UFC em formato csv intitulado “house\_data\_exer\_tnkc\_wobasement.”

---

Primeiro vamos carregar e guardar os nossos dados na variável `dados`:

```
dados <- read.csv("house_data_exer_tnkc_wobasement.csv")
```

```
head(dados)
```

```
##   i..price bedrooms bathrooms sqft_living sqft_lot floors waterfront view
## 1   364000         4        1.75       2010    8625     1           0     0
## 2   875000         5        3.25       4230   21455     2           0     0
## 3  1406890         5        2.25       3580   16789     2           0     0
## 4   550000         3        1.75       1410    5000     1           0     0
## 5  1240000         5        4.00       4410   14380     2           0     0
## 6   326100         2        1.00        880    7683     1           0     0
##   condition grade sqft_above yr_built
## 1         4     7      1340    1957
## 2         3    10      2720    1990
## 3         5     9      3580    1966
## 4         4     7       810    1923
## 5         3    11      4410    2006
## 6         3     6       880    1942
```

Para facilitar nossa vida, vamos renomear a primeira coluna, para `price`

```
names(dados)[1] <- "price"
```

Pra garantir que o nosso *number generator* seja igual ao da questão, vamos utilizar o comando `base::set.seed()`

```
set.seed(123)
```

Agora vamos separar nossa base em *treino* e *teste*

```
## separamos os dados entre treino e teste para evitar overfitting
index <- sample(nrow(dados), nrow(dados)*0.80)
dados.train <- dados[index,]
```

```

dados.test <- dados[-index,]

index_y <- which(colnames(dados)=="price")

#Como o pacote `glmnet` não aceita dataframes, precisamos converter
#os dados para matrix
X.train <- as.matrix(dados.train[,-index_y])
Y.train <- as.matrix(dados.train[,index_y])

X.test <- as.matrix(dados.test[,-index_y])
Y.test <- as.matrix(dados.test[,index_y])

```

## Primeira Questão

Estime modelo de previsão usando MQO

---

Para estimar o modelo de Mínimo Quadrados Ordinários (MQO), precisamos utilizar a função `lm`

## Segunda Questão


Estime modelo de previsão usando Ridge

Para o modelo Ridge temos que minimizar a seguinte função:  $\beta$


```

ridge.fit <- glmnet(x= X.train, y=Y.train, family="gaussian", alpha=0)
plot(ridge.fit, xvar="lambda", label=TRUE)

```



```
cv.ridge <- cv.glmnet(x=X.train, y=Y.train, family="gaussian", alpha=0, nfolds=10)
plot(cv.ridge)
```



```
coef(cv.ridge, s=cv.ridge$lambda.min)
```

```
## 12 x 1 sparse Matrix of class "dgCMatrix"
##              s1
## (Intercept)  5.280961e+06
## bedrooms    -2.820557e+04
## bathrooms    4.685924e+04
## sqft_living   1.354207e+02
## sqft_lot     -2.332355e-01
## floors       1.003572e+04
## waterfront   5.335569e+05
## view         5.707396e+04
## condition    1.827411e+04
## grade        1.094731e+05
## sqft_above    3.983643e+01
## yr_built     -3.057854e+03
```


```
Y_pred.ridge <- predict(ridge.fit, newx = X.test, s=cv.ridge$lambda.min)
```

```
MSE_ridge=mean((Y.test-Y_pred.ridge)^2)
```


## Terceira Questão

Estime modelo de previsão usando Lasso

```
lasso.fit <- glmnet(x=X.train, y=Y.train, family="gaussian", alpha=1)
plot(lasso.fit, xvar="lambda", label=TRUE)
```



```
cv.lasso <- cv.glmnet(x=X.train, y=Y.train, family="gaussian", alpha=1, nfolds=10)
plot(cv.lasso)
```



```
coef(cv.lasso, s=cv.lasso$lambda.min)
```

```
## 12 x 1 sparse Matrix of class "dgCMatrix"
##              s1
## (Intercept)  5.899854e+06
## bedrooms    -3.694220e+04
## bathrooms    3.701211e+04
## sqft_living   1.771408e+02
## sqft_lot      -2.491870e-01
## floors        2.121299e+04
## waterfront    5.601319e+05
## view          4.920484e+04
## condition     1.413335e+04
## grade         1.213249e+05
## sqft_above     1.598994e+00
## yr_built      -3.402046e+03
```

```
Y_pred.lasso <- predict(lasso.fit, newx = X.test, s=cv.lasso$lambda.min)
```


```
MSE_lasso <- mean((Y.test-Y_pred.lasso)^2)
```

Qual o melhor modelo? Justifique.


## Questão Extra

Ponto extra: Estime modelo de previsão usando Elastic-net (com  $\alpha = \{0.25; 0.5; 0.75\}$ ). Compare com modelos anteriores.

```
elastic.fit <- glmnet(x=X.train, y=Y.train,family="gaussian",alpha=0.75)
plot(elastic.fit,xvar="lambda", label=TRUE)
```



```
cv.elastic <- cv.glmnet(x=X.train, y=Y.train, family="gaussian", alpha=0.75, nfolds=10)
plot(cv.elastic)
```



```
coef(cv.elastic, s=cv.elastic$lambda.min)
```

```
## 12 x 1 sparse Matrix of class "dgCMatrix"
```

```
##              s1
```

```
## (Intercept)  5.904087e+06
```

```
## bedrooms    -3.698330e+04
```

```
## bathrooms    3.734970e+04
```

```
## sqft_living   1.764818e+02
```

```
## sqft_lot      -2.507869e-01
```

```
## floors        2.106140e+04
```

```
## waterfront    5.601952e+05
```

```
## view          4.931320e+04
```

```
## condition     1.423917e+04
```

```
## grade         1.212345e+05
```

```
## sqft_above     2.303345e+00
```

```
## yr_built      -3.404147e+03
```

```
Y_pred.elastic<- predict(elastic.fit, newx = X.test, s=cv.elastic$lambda.min)
```

```
MSE_elastic=mean((Y.test-Y_pred.elastic)^2)
```

```
cbind(MSE_lasso,MSE_elastic)
```

```
##           MSE_lasso MSE_elastic
```

```
## [1,] 53078876009 53075757947
```